

Optimización de portafolios de renta variable mediante variantes híbridas del Algoritmo de Colonia de Abejas Artificiales bajo distintos regímenes de volatilidad

**Trabajo de grado presentado para optar al título de
Magíster en Finanzas**

**Luisa Fernanda Ovalle Arias
Norbey Antonio Pidiache Pérez**

Tutor: Bernardo León

**Universidad Externado de Colombia
Programa de Maestría en Finanzas
Bogotá D.C, 2026**

TABLA DE CONTENIDO

1. Introducción	3
2. Objetivos	6
3. Revisión de literatura	7
4. Metodología	16
5. Resultados	30
6. Conclusiones	40
7. Referencias	42

1. Introducción

En la gestión de portafolios, la asignación óptima de activos continúa siendo un desafío central debido a la variabilidad temporal de los retornos financieros y a la inestabilidad de las correlaciones entre activos, lo que introduce incertidumbre en la estimación del riesgo. Durante periodos de alta volatilidad, las combinaciones de activos que en condiciones normales se consideran óptimas tienden a perder rápidamente su efectividad, reduciendo la capacidad de los inversionistas para sostener estrategias de protección frente a caídas abruptas. En mercados estables pueden encontrarse múltiples combinaciones de activos que ofrecen perfiles de riesgo controlado, pero a medida que la volatilidad aumenta esas alternativas se vuelven escasas y frágiles, generando mayores riesgos de concentración y pérdidas inesperadas.

Si bien el enfoque clásico de media-varianza propuesto por Markowitz constituye la base teórica de la optimización de portafolios moderna, su aplicación práctica enfrenta importantes limitaciones. En particular, la estimación de los rendimientos esperados y de la matriz de covarianzas en contextos de alta dimensionalidad resulta altamente sensible a errores de medición, lo que genera soluciones inestables y poco robustas fuera de muestra. Adicionalmente, el supuesto de estacionariedad implícito en este marco teórico rara vez se cumple en los mercados financieros, donde los parámetros estadísticos evolucionan de manera no lineal a lo largo del tiempo.

Como consecuencia, los portafolios óptimos derivados del enfoque tradicional tienden a presentar problemas de concentración excesiva y una capacidad limitada para adaptarse a cambios abruptos en las condiciones de mercado, lo que ha motivado el desarrollo de metodologías alternativas orientadas a mejorar la robustez y estabilidad de las soluciones. En este sentido, las técnicas de optimización metaheurística han ganado relevancia por su capacidad para explorar espacios de solución complejos, no convexos y de alta dimensión sin requerir supuestos estrictos sobre la distribución de los rendimientos.

Entre estos enfoques, el Algoritmo de Colonia de Abejas Artificiales (Artificial Bee Colony, ABC) se ha consolidado como una herramienta efectiva para problemas de optimización financiera, gracias a su capacidad de exploración global y su flexibilidad para manejar funciones objetivo con múltiples restricciones. Inspirado en el comportamiento colectivo de las abejas en la búsqueda de fuentes de alimento, el

algoritmo ABC permite identificar soluciones cercanas al óptimo global incluso en entornos caracterizados por múltiples óptimos locales. Sin embargo, una de sus principales limitaciones radica en su desempeño durante las etapas de explotación local, lo que puede afectar la convergencia y la estabilidad de las soluciones encontradas.

Con el fin de superar estas limitaciones, en la literatura se han propuesto distintas variantes híbridas del algoritmo ABC que incorporan mecanismos adicionales de búsqueda local. Entre estas, el algoritmo ABC-FA integra el Algoritmo de Luciérnagas (Firefly Algorithm) para mejorar la explotación de las soluciones prometedoras, facilitando la convergencia hacia regiones del espacio de búsqueda con mejor desempeño. Este aspecto resulta especialmente relevante en el contexto de la optimización de portafolios, donde un refinamiento local eficiente contribuye a reducir la volatilidad de los pesos y a mitigar la concentración del riesgo.

Partiendo de estos avances, esta investigación introduce dos modificaciones adicionales: el ABC con exploración mejorada (ABC-FAEM) y el ABC con atracción gravitacional (ABC-GSA). El primero busca ampliar la diversidad de soluciones generadas por la fase exploratoria sin sacrificar la intensificación local, mientras que el segundo incorpora un principio de atracción basado en la fuerza gravitacional para guiar la búsqueda hacia áreas de mayor potencial. La inclusión de estas dos variantes responde a la necesidad de evaluar si mecanismos de exploración más amplios y de convergencia más dirigida permiten mejorar la construcción de portafolios resilientes en contextos de alta volatilidad, superando las limitaciones del modelo original y ofreciendo un desempeño más robusto frente a los benchmarks tradicionales.

La metodología empleada en este trabajo se organiza en tres etapas principales: recopilación y procesamiento de datos financieros, implementación y calibración de los algoritmos, y evaluación comparativa del desempeño de las soluciones generadas.

1. Recopilación y procesamiento de datos financieros:

- Se construyó un universo de activos multisectoriales a partir de precios históricos del índice Nasdaq-100.
- Se aplicaron técnicas de filtrado basadas en el puntaje Z-Score para seleccionar los activos más representativos y mitigar problemas de dimensionalidad y sesgo en la selección de activos.

- Los retornos se calcularon en frecuencias diarias y se estandarizaron para asegurar comparabilidad entre activos, preservando sus características de volatilidad y correlación.
2. Implementación y calibración de los algoritmos:
 - Se programaron las versiones del Algoritmo de Colonia de Abejas (ABC), incluyendo tanto el modelo original como las variantes propuestas.
 - Cada algoritmo fue calibrado de manera individual, ajustando parámetros como número de abejas, iteraciones máximas y umbrales de abandono, con base en la literatura y pruebas piloto.
 - Para las variantes introducidas (ABC con exploración mejorada y ABC con atracción gravitacional), se incorporaron mecanismos de búsqueda guiada con el objetivo de evaluar su impacto sobre la convergencia y la diversidad de soluciones.
 3. Evaluación comparativa del desempeño:
 - El análisis empírico se realizó mediante un esquema de ventanas móviles que abarca tanto periodos de estabilidad como fases de crisis y alta incertidumbre: la crisis financiera de 2008, la pandemia de COVID-19 en 2020 y la guerra de 2022.
 - La segmentación en regímenes de volatilidad constituye el núcleo del diseño experimental, pues permite observar no solo el desempeño promedio de cada algoritmo, sino también su capacidad de adaptación cuando cambian las condiciones del mercado.
 - El desempeño de los portafolios se evaluó a partir de métricas de riesgo-retorno (ratio de Sortino, alfa de Jensen, drawdown máximo) y de diversificación (cardinalidad y concentración de pesos).
 - Se aplicaron pruebas de significancia estadística (Wilcoxon sobre Sortino) para determinar si las diferencias observadas entre algoritmos eran consistentes o atribuibles al azar.

La hipótesis central de este trabajo sostiene que la incorporación de mecanismos de exploración guiada en el Algoritmo de Colonia de Abejas (ABC) permite mejorar la construcción de portafolios frente a diferentes regímenes de volatilidad, generando soluciones más estables y con una relación riesgo-retorno más favorable en comparación con el algoritmo estándar y con los enfoques tradicionales de referencia. Al evaluar periodos de estabilidad, crisis financieras y fases de incertidumbre elevada, se busca

determinar si estas variantes logran mantener un desempeño robusto pese a la variabilidad de las condiciones de mercado.

Los resultados empíricos muestran que las variantes propuestas superan al ABC original y a benchmarks como la optimización media-varianza de Markowitz y la asignación equitativa $1/N$. En particular, destacan mejoras consistentes en métricas de desempeño ajustadas al riesgo, como el ratio de Sortino y el alfa de Jensen, junto con un mayor control del drawdown y una diversificación más equilibrada, reflejada en una cardinalidad eficiente y en menores niveles de concentración. Estas evidencias confirman que, al introducir mecanismos de exploración guiada, es posible construir portafolios con mayor capacidad de adaptación y resiliencia ante perturbaciones en los datos y cambios en los regímenes de volatilidad, lo que refuerza la pertinencia de los modelos propuestos como alternativas viables en la gestión moderna de portafolios.

2. Objetivos

a. Objetivo general

Evaluar el desempeño de variantes híbridas del Algoritmo de Colonia de Abejas Artificiales (ABC), específicamente el ABC-FA con exploración mejorada (ABC-FAEM) y el ABC con atracción gravitacional (ABC-GSA), en la optimización de portafolios de renta variable del NASDAQ-100 bajo distintos regímenes de volatilidad, con el fin de determinar si los mecanismos de exploración guiada permiten construir portafolios más resilientes y eficientes en comparación con el algoritmo estándar y los enfoques tradicionales de referencia.

b. Objetivos específicos:

1. Diseñar e implementar las variantes ABC-FAEM y ABC-GSA, incorporando mecanismos de exploración guiada basados en la atracción por luciérnagas y en la fuerza gravitacional dentro de la fase de scout del algoritmo ABC, y calibrar sus hiperparámetros mediante una metodología de regímenes sintéticos de volatilidad.
2. Evaluar comparativamente el desempeño de los algoritmos propuestos frente al ABC original y a los benchmarks tradicionales (optimización Media-Varianza y

asignación equiponderada $1/N$) en regímenes de crisis (GFC 2008, COVID-19 2020), volatilidad elevada (guerra 2022) y estabilidad (2023–2024), utilizando métricas de riesgo-retorno, riesgo extremo y diversificación.

3. Determinar el efecto de la selección de universo de activos mediante Z-score (dinámico de mercado y de fundamentales financieros) sobre la resiliencia, diversificación y eficiencia de los portafolios optimizados, evaluando su contribución como capa de preprocesamiento adaptativo dentro de la arquitectura de optimización propuesta.

3. Revisión de literatura

La Teoría Moderna de Portafolio, formulada por Harry Markowitz en 1952, sentó las bases cuantitativas para diversificar el riesgo mediante la construcción de portafolios eficientes. Su propuesta parte del supuesto de racionalidad en los agentes y mercados eficientes, optimizando la asignación de activos a partir de la minimización de la varianza para un nivel esperado de retorno, o la maximización del retorno para un nivel dado de riesgo. Este enfoque se formaliza mediante el siguiente problema cuadrático de optimización:

Minimizar:

$$Var(Rp) = w^T \Sigma w \quad (1)$$

Sujeto a:

$$\sum_{i=1}^n w_i = 1 \quad (2)$$

$$\mu^T w \geq r \quad (3)$$

donde w es el vector de pesos, Σ es la matriz de varianzas y covarianzas, μ el vector de retornos esperados y r el retorno mínimo deseado. El resultado de esta optimización define la frontera eficiente, que representa los portafolios con la mejor relación riesgo-retorno

disponibles para cada nivel de tolerancia al riesgo. Este principio se fundamenta en la idea de que, al diversificar adecuadamente entre activos con correlaciones imperfectas, se reduce el riesgo no sistemático y se logra maximizar el retorno ajustado por la volatilidad.

A pesar de su importancia histórica, la aplicación práctica del modelo de Markowitz revela limitaciones significativas. En particular, el supuesto de normalidad en la distribución de los retornos, así como la hipótesis de inversores perfectamente racionales con información completa, rara vez se cumplen en los mercados financieros reales, donde las correlaciones entre activos pueden variar de forma no lineal y los rendimientos suelen exhibir colas pesadas. Además, la fuerte dependencia de la estimación de parámetros, especialmente de la matriz de covarianza, implica que pequeñas variaciones en los datos o el uso de muestras de tamaño reducido introduzcan ruido y generen asignaciones extremas poco estables. Estas dificultades se agudizan a medida que crece el número de activos, dado que la mayor dimensionalidad exige historiales amplios y estadísticamente estables que, en la práctica, no siempre están disponibles, dando lugar a portafolios frágiles, mal diversificados y altamente sensibles a cambios de régimen de volatilidad. Finalmente, los enfoques basados en programación cuadrática o lineal pueden volverse computacionalmente costosos o incluso inviables cuando se incorporan múltiples restricciones adicionales, como límites de exposición, requerimientos regulatorios o condiciones de liquidez, lo que prolonga los tiempos de cálculo y dificulta la validación fuera de muestra.

Para abordar algunas de estas deficiencias, James Tobin introdujo en 1958 la noción de la Línea del Mercado de Capitales (Capital Market Line, CML) al incorporar un activo libre de riesgo en la construcción de portafolios, de manera que los inversores pudieran combinar una cartera de mercado óptima con un bono sin riesgo y seleccionar, a lo largo de la CML, el nivel de riesgo consistente con su grado de aversión. Este avance permitió ajustar de forma continua la exposición al riesgo sistémico sin modificar la composición relativa de los activos riesgosos, ampliando la flexibilidad del esquema original de Markowitz. No obstante, este enfoque mantiene la dependencia de parámetros estimados y del supuesto de estabilidad en la estructura de correlaciones, por lo que sus mejoras resultan limitadas frente a entornos caracterizados por cambios de régimen de volatilidad.

En 1964, William Sharpe formuló el Modelo de Valoración de Activos de Capital (CAPM), que relaciona el rendimiento esperado de un activo con su riesgo sistemático, medido por el coeficiente beta. Según el CAPM, el rendimiento esperado de un activo se calcula como

$$E(R_i) = R_f + \beta_i(E(R_m) - R_f) \quad (4)$$

donde $E(R_i)$ es el rendimiento esperado del activo, R_f es el rendimiento libre de riesgo, β_i es el beta del activo (que mide su riesgo en relación con el mercado), y $E(R_m)$ es el rendimiento esperado del mercado. Aunque el CAPM simplifica el análisis al suponer que un único factor sistemático explica los retornos, ha sido cuestionado por no capturar otros factores de riesgo y por depender de supuestos de eficiencia de mercado que no siempre se cumplen.

Más adelante, el modelo de tres factores de Fama y French (1992) añadió dos variables adicionales: tamaño de la empresa y valor versus crecimiento, en un intento de explicar variaciones en los retornos que el CAPM no abordaba. Este modelo demostró que las empresas pequeñas y las de valor tienden a ofrecer primas de riesgo extra que no se explican únicamente por el beta de mercado. Paralelamente, el Modelo de Arbitraje de Precios (APT) de Stephen Ross (1976) permitió incorporar múltiples factores macroeconómicos en la explicación de los retornos, sin requerir que los inversores diversifiquen completamente, ofreciendo mayor flexibilidad para reflejar la influencia de indicadores económicos como inflación, tasas de interés o crecimiento del PIB.

El modelo Black–Litterman (1990) representa otra extensión significativa, combina las expectativas subjetivas de los inversores con las observaciones implícitas en los precios de mercado, mitigando la excesiva sensibilidad del modelo de Markowitz a errores de estimación de la covarianza. Al partir de una postura de equilibrio, ajusta las ponderaciones de la cartera según opiniones del gestor, resultando en asignaciones más estables y realistas. A su vez, los enfoques de paridad de riesgo (risk parity) asignan el riesgo de manera equitativa entre los activos en lugar de basarse únicamente en correlaciones, generando portafolios más equilibrados que eviten que un activo o sector domine la exposición total al riesgo, lo cual resulta crucial en entornos de mercado volátiles.

Con el avance tecnológico, la programación cuadrática contribuyó a optimizar el modelo de Markowitz con restricciones lineales y no lineales, permitiendo resolver portafolios con numerosas variables y condiciones operativas realistas, como límites de exposición o restricciones regulatorias, tal como se formaliza en el marco de optimización con restricciones propuesto por Jagannathan y Ma (2003). Sin embargo, cuando la dimensionalidad crece, el costo computacional aumenta drásticamente y la matriz de covarianza estimada a partir de muestras históricas puede reducir la robustez de la solución,

problema asociado al error de estimación y a la inestabilidad fuera de muestra señalada por Michaud (1989) y DeMiguel, Garlappi y Uppal (2009).

Por su parte, la optimización multiperíodo, inspirada en los trabajos seminales de Robert C. Merton (1969, 1971), buscó incorporar dinámicas intertemporales para ajustar estrategias de inversión a lo largo del tiempo, considerando escenarios de cobertura y reequilibrio periódico. Aunque este enfoque ofrece una visión más realista para carteras de largo plazo, su desempeño sigue estando condicionado por la calidad de la estimación de parámetros y por la dificultad de modelar adecuadamente la incertidumbre dinámica, en particular frente a cambios de régimen de volatilidad, como discuten Campbell y Viceira (2002).

Frente a estas limitaciones estructurales, especialmente en contextos de alta volatilidad como crisis financieras, shocks geopolíticos o eventos exógenos de mercado, han cobrado relevancia los enfoques basados en inteligencia colectiva e inspiración biológica. Estos modelos, conocidos como metaheurísticos, constituyen técnicas de optimización basadas en mecanismos estocásticos, que prescinden de supuestos de convexidad y normalidad en las distribuciones, y permiten explorar de forma más efectiva espacios de solución complejos, no lineales y con múltiples restricciones. La literatura destaca que estas técnicas ofrecen ventajas asociadas a la capacidad de exploración global del espacio de soluciones y a su aplicabilidad en problemas complejos y dinámicos, donde los métodos tradicionales basados en programación matemática tienden a enfrentar limitaciones prácticas (Blum y Roli, 2003; Talbi, 2009).

En este contexto, el Algoritmo de Colonia de Abejas Artificiales (ABC), propuesto por Karaboga (2005), se ha consolidado como una herramienta efectiva en la búsqueda global de soluciones robustas. El ABC simula la dinámica de una colmena distribuida en tres tipos de abejas: empleadas, observadoras y exploradoras. Las abejas empleadas exploran vecindarios de soluciones conocidas, las observadoras seleccionan soluciones prometedoras en función de una regla probabilística, y las exploradoras reemplazan soluciones estancadas por nuevas candidatas aleatorias. Este esquema permite balancear exploración y explotación de forma descentralizada, lo cual resulta adecuado en problemas de alta dimensionalidad con múltiples óptimos locales. Formalmente, la actualización de soluciones en el ABC se realiza mediante la siguiente fórmula:

$$v_{ij} = x_{ij} + \phi_{ij}(x_{ij} - x_{kj}) \quad (5)$$

donde x_{ij} representa el valor de la solución actual en la dimensión j , x_{kj} una solución aleatoria distinta, y ϕ_{ij} es un número aleatorio uniforme en $[-1,1]$ que introduce variación. Esta fórmula permite generar soluciones vecinas en torno a una referencia dada, facilitando la exploración local controlada. Aunque este enfoque ha mostrado eficacia, su fase de explotación es limitada y el reemplazo aleatorio en las abejas exploradoras puede afectar la convergencia, reduciendo la estabilidad de los resultados en aplicaciones financieras.

Por otro lado, la literatura ha propuesto múltiples enfoques híbridos que integran principios de distintos algoritmos bioinspirados, con el objetivo de aprovechar sus ventajas complementarias en términos de exploración y explotación. Estas aproximaciones han demostrado ser especialmente útiles en entornos caracterizados por alta incertidumbre, al permitir que el proceso de búsqueda se adapte dinámicamente en función del desempeño relativo de las soluciones y de su posición en el espacio de búsqueda, mitigando así problemas de convergencia prematura o estancamiento en óptimos locales.

En particular, con el fin de reforzar los mecanismos de explotación del algoritmo ABC, surge una variante denominada ABC-FA, que reemplaza el mecanismo puramente aleatorio asociado a las abejas exploradoras por una estrategia guiada inspirada en el Algoritmo de Luciérnagas (Firefly Algorithm, FA), propuesto por Yang (2008). Este algoritmo modela la atracción entre luciérnagas como una función decreciente de la distancia entre soluciones, de modo que aquellas con mejor evaluación actúan como polos de atracción para las demás. Este cambio responde a la necesidad de superar una de las principales debilidades del ABC original, relacionada con una explotación local limitada, dado que la sustitución completamente aleatoria de soluciones estancadas puede ralentizar la convergencia y generar resultados inestables. El modelo matemático de movimiento entre luciérnagas se expresa como:

$$x_i^{t+1} = x_i^t + \beta_0 e^{-\gamma r_{ij}^2} (x_j^t - x_i^t) + \alpha \epsilon_i \quad (6)$$

donde x_i y x_j son luciérnagas, β_0 es el grado de atracción inicial, γ controla la tasa de decaimiento con la distancia r_{ij} , y ϵ_i representa una perturbación aleatoria controlada por α . La incorporación de esta lógica al rol de las abejas exploradoras garantiza que las soluciones descartadas se sustituyan de manera más informada, orientándose hacia regiones del espacio de búsqueda con mayor potencial. De esta forma, la variante ABC-FA mejora la eficiencia exploratoria y refuerza la explotación sin sacrificar la diversidad, lo cual resulta

especialmente relevante en escenarios financieros donde los cambios de régimen limitan las oportunidades de diversificación.

Otra línea de inspiración se deriva del Algoritmo de Búsqueda Gravitacional (GSA), desarrollado por Rashedi et al. (2009), el cual considera a cada agente como una masa que se mueve bajo la influencia de fuerzas gravitacionales determinadas por el valor de aptitud relativo entre soluciones. En este marco, se considera que cada partícula ejerce una atracción proporcional a su calidad, generando un efecto de intensificación cooperativa que dirige el movimiento colectivo hacia zonas de mayor desempeño. Formalmente, la fuerza ejercida por una solución j sobre otra i se modela como:

$$F_{ij}^d(t) = G(t) \cdot \frac{M_i(t) \cdot M_j(t)}{R_{ij}(t) + \varepsilon} \cdot (x_j^d(t) - x_i^d(t)) \quad (7)$$

donde $M_i(t)$ representa la masa (derivada del valor de aptitud) del agente i en el tiempo t , $R_{ij}(t)$ es la distancia euclidiana entre dos soluciones, $G(t)$ es una constante gravitacional decreciente, y ε es un término pequeño para evitar divisiones por cero. La introducción de este mecanismo dentro del esquema ABC aporta un balance entre intensificación y diversificación, lo que en el dominio financiero se traduce en una mayor capacidad para mantener la estabilidad de los portafolios frente a perturbaciones abruptas y para evitar pérdidas de convergencia en periodos de alta volatilidad.

Ambas propuestas de la literatura, el ABC clásico y su extensión con luciérnagas (ABC-FA), constituyen un punto de partida sólido pero no exento de limitaciones. El primero suele presentar baja convergencia debido a que reemplaza soluciones de forma completamente aleatoria, mientras que el segundo, aunque introduce un reemplazo guiado más eficiente, puede aún mostrar inestabilidad en escenarios de elevada volatilidad. Sobre esta base, el aporte central de la tesis consiste en desarrollar dos variantes que buscan superar estas debilidades y adaptarse mejor a distintos regímenes de volatilidad: el ABC-FA con exploración mejorada (ABC-FA-EM) y el ABC gravitacional (ABC-GSA). La primera refuerza la fase de intensificación del ABC-FA al optimizar la lógica de atracción inspirada en el Algoritmo de Luciérnagas, mejorando la precisión en la búsqueda de regiones prometedoras. La segunda sustituye la lógica aleatoria del ABC original por un mecanismo de interacción gravitacional, que fomenta la cooperación entre soluciones y acelera la convergencia en entornos altamente volátiles.

Para contextualizar estos modelos frente a alternativas tradicionales y heurísticas, se presenta a continuación una tabla comparativa que sintetiza sus características principales:

Modelo	Tipo de optimización	Parametrización	Ventajas	Desventajas
1/n (Equiponderado)	No requiere optimización (heurística fija)	Ninguna	Simplicidad extrema y robustez frente a errores de estimación. Complejidad computacional nula.	Ignora la estructura de riesgo y correlaciones. No es adaptativo. Mal desempeño frente a choques extremos y en alta volatilidad.
Media-Varianza (MV)	Convexa, cuadrática	Requiere estimación de μ y de la matriz Σ	Fundamento teórico claro y fácil interpretación financiera. Óptimo en entornos con supuestos estables.	Muy sensible a errores en la estimación de Σ . Tendencia a asignaciones extremas y mal desempeño fuera de muestra. Coste computacional y limitaciones al añadir restricciones realistas.
ABC (Karaboga)	No convexa, estocástica	SN, limit, max_iter	Maneja restricciones no convexas y explora globalmente	Exploración global buena pero explotación local limitada, lo que puede

			espacios complejos.	traducirse en baja convergencia al óptimo en entornos complejos. Puede requerir reinicializaciones y ajuste de parámetros.
ABC-FA (Bacanin)	No convexa, estocástica	SN, limit, max_iter, β_0 , γ , α	Reemplazo dirigido de soluciones estancadas mediante atracción tipo luciérnaga, mejora la explotación local respecto al ABC básico. Más robusto en entornos ruidosos.	Cálculo de distancias y evaluación adicional incrementan costo computacional. Dependencia de la calibración de parámetros de atracción; riesgo de sobreajuste local si no se valida.
ABC-FA-EM (Propuesta)	No convexa, estocástica	SN, limit, max_iter, α , b_0 , γ , max_trials, numb_bees	Exploración guiada diseñada para mejorar la explotación sin perder diversidad. Se implementa para favorecer	Mayor número de parámetros que requieren calibración por validación cruzada. Coste computacional

			convergencia controlada y adaptabilidad a cambios de régimen evitando un sobreajuste. Mejora la capacidad para encontrar soluciones robustas en presencia de ruido.	superior al ABC básico.
ABC-GSA (Propuesta)	No convexa, estocástica	SN, limit, max_iter, G(t), ϵ , parámetros de masa/atracción, numb_bees	Cobertura amplia del espacio de búsqueda y dinámica cooperativa que favorece la intensificación hacia regiones de alto desempeño. Efectivo en volatilidad alta y paisajes multimodales.	Complejidad computacional elevada y alta sensibilidad a la calibración de parámetros gravitacionales. Riesgo de concentración de pesos si no se ajusta la regularización.

Como se evidencia en la tabla comparativa, estas variantes no solo fortalecen el equilibrio entre exploración y explotación, sino que también incrementan la robustez de los portafolios

frente a perturbaciones en los datos y cambios abruptos de régimen. En consecuencia, se consolidan como herramientas metodológicas con mayor potencial que los enfoques clásicos, como la optimización media-varianza de Markowitz o la asignación equitativa 1/N, ofreciendo soluciones más consistentes, diversificadas y eficientes bajo condiciones reales de incertidumbre.

4. Metodología

La presente sección expone en detalle el marco metodológico utilizado en esta investigación, cuyo objetivo es evaluar el desempeño de variantes del Algoritmo de la Colonia de Abejas Artificiales (ABC) en la optimización de portafolios bajo distintos regímenes de volatilidad. La metodología se organiza en seis etapas secuenciales: (1) definición del universo de activos y selección mediante filtros de Z-score, (2) formulación matemática del problema de optimización, (3) descripción de los modelos de optimización implementados, (4) calibración de parámetros y construcción de regímenes sintéticos de volatilidad, (5) definición de métricas de desempeño y función de utilidad, y (6) diseño de escenarios de validación y backtesting fuera de muestra.

4.1. Definición del universo de activos y selección inicial: El universo de inversión se basa en el índice NASDAQ-100, compuesto por 100 de las empresas no financieras más representativas del mercado estadounidense. Este índice ofrece un entorno empírico adecuado para la evaluación de heurísticas bioinspiradas, debido a su alta liquidez, marcada exposición a episodios de volatilidad y correlaciones sectoriales relevantes. Para seleccionar los activos candidatos se aplica un doble filtro Z-score, cuyo propósito es combinar señales de desempeño reciente en precios con indicadores de solidez financiera:

4.1.1. Z-score dinámico de mercado: En el contexto de la optimización de portafolios, la selección del universo de activos es una decisión crítica que puede introducir sesgos significativos, especialmente el "look-ahead bias", si se basa en información que no esté disponible en el momento de la optimización. Para mitigar este riesgo y asegurar una metodología robusta, se ha implementado un Z-score dinámico.

La selección de activos mediante este Z-score no interviene directamente en la mecánica interna del algoritmo ABC, no modifica el comportamiento de las abejas empleadas, observadoras o exploradoras, ni la forma en que estas interactúan con las

fuentes de alimento (soluciones de portafolio). En su lugar, el Z-score dinámico actúa como un filtro de pre-procesamiento adaptativo, definiendo en cada momento de ejecución del algoritmo el conjunto de activos elegibles para la optimización.

El propósito de este Z-score dinámico es permitir la identificación de un subconjunto de activos potenciales en cada momento del tiempo, basándose exclusivamente en la información disponible hasta esa fecha, preservando la coherencia temporal del proceso de selección y evitando sesgos derivados del uso de información futura.

El Z-score dinámico se calcula a partir de una combinación ponderada de momentum (retornos acumulados), volatilidad (desviación estándar de retornos) y Max Drawdown, todos extraídos de los retornos históricos de los activos. Su naturaleza dinámica se define por su reevaluación en cada período de rebalanceo, utilizando una ventana móvil de datos históricos previa a la fecha de inicio de la optimización.

- 4.1.2. Z-score de fundamentales financieros: Este enfoque de selección incorpora indicadores de rentabilidad, valoración relativa, crecimiento, apalancamiento y riesgo financiero, con el objetivo de construir una evaluación multidimensional del valor y la solidez de los activos.

El Z-score de fundamentales se basa en métricas de rentabilidad (Net Margin, Return on Average Common Equity, Return on Average Total Assets), ratios de valoración relativa (PE, Price to Book Value per Share, Price / Total Revenue per Share) y perspectivas de crecimiento derivadas de estimaciones de mercado (Price / EPS SmartEstimate, Price / Earnings to Growth Ratio). Adicionalmente, se incorporan indicadores de apalancamiento y solidez financiera, como el Current Ratio y el Total Debt to Common Equity en sus valores actuales y de largo plazo, permitiendo que el proceso de selección refleje no solo el desempeño histórico de los precios, sino también características estructurales asociadas a la calidad financiera de las empresas.

La estandarización mediante Z-score asegura comparabilidad entre métricas heterogéneas. Formalmente, para cada variable X_i :

$$Z_i = \frac{X_i - \bar{X}}{\sigma} \quad (8)$$

Donde $\bar{X}$ y σ corresponden al promedio y la desviación estándar de la variable en el universo considerado. Los activos seleccionados cumplen además condiciones de estabilidad y liquidez, incluyendo un historial mínimo de tres años de precios continuos y un volumen medio diario superior a 500 mil acciones. Con ello, se garantiza la replicabilidad de los resultados en condiciones de mercado real.

4.2. Formulación matemática del problema de optimización: El problema de optimización de portafolios consiste en determinar los pesos w_i asignados a cada activo financiero $i=1,2, \dots, N$, con el fin de maximizar la rentabilidad ajustada por riesgo bajo restricciones realistas de inversión. El retorno esperado del portafolio se expresa como:

$$R_p = \sum_{i=1}^N w_i \mu_i \quad (9)$$

donde μ_i es el retorno esperado del activo i .

El riesgo del portafolio se mide mediante la varianza de los retornos:

$$\sigma_p^2 = \sum_{i=1}^N \sum_{j=1}^N w_i w_j \sigma_{ij} \quad (10)$$

donde σ_{ij} representa la covarianza entre los activos i y j

Las restricciones básicas aseguran que los pesos sean factibles:

$$\sum_{i=1}^n w_i = 1 \quad (11)$$

$$0 \leq w_i \leq 1 \quad \forall i \quad (12)$$

Esto implica que no se permite apalancamiento ni posiciones cortas.

4.2.1. Función de utilidad multiobjetivo: Para capturar de forma integral el compromiso entre retorno, riesgo y diversificación, se define la siguiente función de utilidad:

$$U(w) = Sortino(w) + \Omega(w) - \lambda \cdot CVaR(w) - \eta \cdot HHI(w) \quad (13)$$

Donde,

- 4.2.1.1. Ratio de Sortino ($Sortino(w)$): Mide la eficiencia del portafolio en generar retornos positivos por unidad de riesgo negativo:

$$Sortino(w) = \frac{E[R_p - r_f]}{\sigma_d} \quad (14)$$

R_p es el retorno del portafolio, r_f la tasa libre de riesgo y σ_d la desviación estándar de los retornos negativos. Los valores altos indican que el portafolio genera buenos retornos ajustados por pérdidas. Mientras que los valores bajos o negativos implican que la estrategia no compensa los riesgos asumidos. Se prioriza este ratio sobre el ratio de Sharpe porque en entornos volátiles penalizar solo la variabilidad negativa es más relevante.

- 4.2.1.2. Índice Omega ($\Omega(w)$): Captura la relación entre ganancias y pérdidas frente a un umbral mínimo de rentabilidad θ :

$$\Omega(w) = \frac{\int_{\theta}^{\infty} [1 - F(r)] dr}{\int_{-\infty}^{\theta} F(r) dr} \quad (15)$$

$F(r)$ es la función de distribución acumulada de los retornos y θ es el retorno mínimo aceptable (benchmark). Cuando $\Omega > 1$ predominan escenarios de ganancias, por el contrario cuando $\Omega < 1$ predominan escenarios de pérdidas. Este indicador es flexible porque incorpora toda la distribución de retornos, no solo su media y varianza.

- 4.2.1.3. Valor en Riesgo Condicional ($CVaR(w)$): Mide la pérdida promedio esperada en los peores escenarios con nivel de confianza α :

$$CVaR_{\alpha}(w) = -E[R_p \leq VaR_{\alpha}] \quad (16)$$

Los valores bajos implican un portafolio más robusto frente a pérdidas extremas mientras que valores altos implican mayor exposición a “colas pesadas” en la distribución de retornos. Incorporar CVaR asegura que el modelo no favorezca soluciones que maximizan rentabilidad sacrificando estabilidad.

- 4.2.1.4. Índice de Herfindahl-Hirschman (HHI): Mide la concentración del portafolio en pocos activos:

$$HHI(w) = \sum_{i=1}^N w_i^2 \quad (17)$$

Los valores bajos implican un portafolio diversificado mientras que los valores altos muestran concentración en pocos activos (mayor riesgo idiosincrático). Al penalizar el HHI, se incentiva la construcción de carteras diversificadas y más estables.

4.2.1.5. Objetivo del modelo: En conjunto, la función de utilidad busca: Maximizar la eficiencia (Sortino, Omega), controlar las pérdidas extremas (CVaR) y evitar concentración excesiva (HHI). De esta forma, el modelo no solo selecciona activos con buenos retornos esperados, sino que aprende a adaptarse a entornos volátiles y cambios de régimen, equilibrando exploración y explotación en la búsqueda de portafolios robustos.

4.3. Modelos de optimización: El proceso de entrenamiento de los modelos bioinspirados propuestos se estructura de forma coherente con la lógica evolutiva de algoritmos estocásticos y con los principios de validación fuera de muestra exigidos por entornos financieros reales. Dado que el rendimiento de un algoritmo de optimización puede verse afectado significativamente por las condiciones del mercado, esta sección detalla el proceso de entrenamiento y calibración de los modelos basados en la Colonia de Abejas Artificiales (ABC) y sus variantes, incluyendo los métodos atracción por Luciérnagas (ABC-FA y ABC-FA con explotación mejorada) y gravedad simulada (ABC-GSA), con especial atención a su desempeño durante periodos de alta volatilidad.

4.3.1. Modelo ABC: El algoritmo ABC simula la conducta de búsqueda de alimentos de una colonia de abejas artificiales. Los parámetros principales que se calibran son:

- SN : número de fuentes de alimento (soluciones)
- Limit: límite de intentos sin mejora para abandonar una fuente
- max_iter: número máximo de iteraciones por entrenamiento

Durante el entrenamiento, cada solución representa un vector de pesos del portafolio $w = [w_1, w_2, \dots, w_n]$, el cual satisface las restricciones de factibilidad definidas en las ecuaciones 11 y 12.

La función de aptitud se definió como el retorno ajustado por riesgo, es decir:

$$f(w) = \frac{(\mu_{p(w)} - r_f)}{\sigma_{p(w)}} \quad (18)$$

Donde:

- $\mu_{p(w)}$: retorno esperado del portafolio
- $\sigma_{p(w)}$: desviación estándar del portafolio
- r_f : tasa libre de riesgo

En cada iteración, las abejas empleadas exploran nuevas soluciones vecinas usando:

$$v_{ij} = x_{ij} + \varphi_{ij} * (x_{ij} - x_{kj}) \quad (19)$$

donde $k \neq i$ y $\varphi_{ij} \sim U(-1, 1)$

4.3.2. Modelo ABC-FA (con algoritmo de Luciérnagas): El modelo ABC-FA con explotación mejorada reemplaza la estrategia de movimiento aleatorio de las abejas empleadas por un mecanismo de atracción dirigido, inspirado en el algoritmo de Luciérnagas. Cada solución candidata se mueve hacia otra de mayor aptitud con una intensidad que decrece exponencialmente en función de la distancia:

$$x_i(t+1) = x_i(t) + \alpha * e^{-\gamma * r_{ij}^2} * (x_j(t) - x_i(t)) + \varepsilon \quad (20)$$

Donde:

- r_{ij} : distancia euclidiana entre i y j
- α : factor de movimiento
- γ : parámetro de absorción de luz
- ε : ruido aleatorio para evitar estancamiento

Esta modificación introduce atracción dirigida, mejorando la explotación local sin sacrificar la diversidad global. Su desempeño se ve reforzado durante episodios de volatilidad media-alta, donde se requiere exploración guiada con convergencia controlada.

El modelo híbrido propuesto por Tuba y Bacanin (2014), no integra la ecuación de las luciérnagas directamente en la fórmula de actualización del ABC, sino que la utiliza como una de dos opciones de búsqueda. En cada iteración de la fase de abeja empleada, el algoritmo toma una decisión basada en un mecanismo de "disparador"

que se implementa matemáticamente. Este disparador se basa en un parámetro de probabilidad, PFA , que representa la propensión del algoritmo a usar la estrategia de las luciérnagas. El modelo genera un número aleatorio, r , que sigue una distribución uniforme continua en el intervalo $[0,1]$. Si $r < PFA$, el algoritmo se "dispara" y la abeja utiliza la estrategia de explotación dirigida del FA. Si no, la abeja opta por la estrategia de exploración aleatoria del ABC original. Este mecanismo de decisión probabilística permite al modelo mantener un equilibrio dinámico entre la exploración y la explotación.

4.3.3. Modelo ABC-GSA (con gravedad simulada): En el modelo ABC-GSA, las soluciones están influenciadas por fuerzas gravitacionales, de modo que aquellas con mejor aptitud atraen a otras con una magnitud proporcional a su masa relativa. La fuerza entre partículas i y j se define como:

$$F_{ij(t)} = G(t) * \frac{(M_{i(t)} * M_{j(t)})}{(R_{ij(t)} + \varepsilon)} \quad (21)$$

Donde:

- $G(t)$: constante gravitacional decreciente con el tiempo
- $M_{i(t)}$: masa de la solución basada en su aptitud
- $R_{ij(t)}$: distancia euclidiana entre soluciones

El movimiento se actualiza mediante:

$$a_{i(t)} = \frac{F_{i(t)}}{M_{i(t)}} v_{i(t+1)} = r * v_{i(t)} + a_{i(t)} x_{i(t+1)} = x_{i(t)} + v_{i(t+1)} \quad (22)$$

Este modelo resulta especialmente efectivo en contextos de volatilidad severa, donde se requiere una cobertura amplia del espacio de búsqueda. La gravedad actúa como mecanismo de absorción adaptativa, evitando la sobreexplotación de regiones locales.

4.4. Calibración de parámetros y construcción de regímenes sintéticos: En esta tesis, la calibración de los hiperparámetros de los algoritmos propuestos (ABC-FA-EM, ABC-GSA, y ABC-Original) se aborda mediante una metodología basada en la construcción de regímenes sintéticos. Este enfoque tiene un objetivo dual: evitar el sobreajuste a patrones históricos específicos y preparar los algoritmos para un rendimiento consistente en una amplia gama de condiciones de mercado adversas.

Tradicionalmente, la calibración se realiza sobre datos históricos, lo que puede llevar a soluciones frágiles que se desempeñan pobremente fuera de muestra. Para contrarrestar esto, nuestra estrategia de calibración parte de una matriz base de rendimientos esperados (μ) y covarianzas (Σ) calculada sobre los activos seleccionados mediante el Z-score. Esta matriz no es un simple punto de partida descriptivo, sino la representación empírica de las interrelaciones fundamentales de los activos en un período de referencia.

A partir de esta base, se genera un conjunto de regímenes sintéticos, cada uno diseñado para emular condiciones de mercado que desafían la capacidad de los algoritmos para construir portafolios eficientes. Las transformaciones aplicadas a la matriz base son deliberadas y buscan replicar los estresores financieros más comunes:

- Ajuste de rendimientos esperados: $u' = \mu + \delta_\mu$ con δ_μ . La introducción de un término negativo ($\epsilon < 0$) en los rendimientos esperados no es una mera alteración, sino una simulación de una pérdida generalizada en el mercado. Esto obliga a los algoritmos a optimizar bajo la premisa de retornos decrecientes, un escenario típico en escenarios de crisis o incertidumbre.
- Escalamiento de volatilidades: $\Sigma' = D\Sigma D$ mediante una matriz diagonal (D) con factores de escala mayores que 1, se incrementan las volatilidades individuales. Esta perturbación evalúa la capacidad del algoritmo para manejar el riesgo idiosincrásico amplificado y la sensibilidad a choques específicos de activos.
- Incremento de correlaciones: Se aplica un operador que aumenta los elementos off-diagonal de la matriz de correlaciones para reflejar episodios de flight-to-quality o pánico sistémico, donde la diversificación tradicional se ve comprometida, forzando a los algoritmos a encontrar soluciones robustas en entornos de alta interdependencia.

La combinación de estas transformaciones genera un conjunto diverso de paisajes de optimización, que incluyen situaciones de alta correlación con caídas generalizadas, alta volatilidad focalizada en sectores específicos, y períodos de estabilidad relativa. Esta diversidad es fundamental para garantizar que el algoritmo no solo funcione en condiciones "normales", sino que exhiba una adaptabilidad superior ante la complejidad inherente de los mercados financieros.

El escenario sintético contempla perturbaciones que replican los tres tipos de entornos que se evaluarán fuera de muestra: crisis sistémica, volatilidad elevada y estabilidad. El objetivo es cubrir la diversidad de paisajes de optimización que el algoritmo podría enfrentar en la práctica.

Para cada algoritmo se ejecuta un grid search amplio sobre los hiperparámetros relevantes (por ejemplo número de abejas, limit, iteraciones, parámetros FA α , γ , constantes gravitacionales, etc.). La búsqueda se realiza en dos fases:

- 4.4.1. Exploratoria amplia: Esta etapa inicial no busca la precisión fina, sino la identificación de regiones prometedoras en el espacio de parámetros. Se explora un rango amplio de valores para los hiperparámetros (como el número de abejas y el límite en ABC, las constantes α y γ en Firefly Algorithm, o las constantes gravitacionales en el método gravitacional), utilizando una granularidad más gruesa.
- 4.4.2. Refinamiento local: Una vez identificadas las regiones de interés, se realiza una búsqueda más fina. El objetivo es minimizar la función de pérdida $-U(w)$, que representa la utilidad del portafolio, garantizando que los parámetros seleccionados converjan hacia soluciones que maximicen la función objetivo promedio sobre el conjunto de regímenes sintéticos.

El criterio de selección final de los parámetros no se limita a la maximización de la función objetivo promedio. Un aspecto importante es la estabilidad de los resultados entre múltiples ejecuciones con diferentes semillas aleatorias. Esto asegura que los parámetros elegidos no sólo ofrecen un buen rendimiento promedio, sino que también son inherentemente estables y menos susceptibles a la variabilidad estocástica del algoritmo

- 4.5. Entrenamiento y puesta en práctica de los algoritmos: Esta sección articula las dos fases fundamentales en el ciclo de vida de los algoritmos de optimización de portafolios desarrollados en esta investigación: la calibración de parámetros en entornos controlados y la validación empírica mediante backtesting. Cada fase se distingue por sus objetivos metodológicos y por la rigurosidad en la aplicación de los procedimientos.
 - 4.5.1. Entrenamiento: Los algoritmos se inicializan con parámetros candidatos y se ejecutan repetidas veces sobre conjuntos de datos generados a partir de las matrices estresadas. En cada corrida se evalúa la función objetivo y métricas secundarias. Los resultados consolidados permiten seleccionar las combinaciones de parámetros que maximizan la robustez media y reducen la varianza de desempeño entre semillas.
 - 4.5.2. Puesta en práctica y evaluación fuera de muestra: Una vez seleccionados los parámetros para cada régimen sintético, los modelos se aplican fuera de muestra sobre periodos históricos representativos. Estos periodos sirven únicamente como test para

evaluar la capacidad de adaptación estructural de las configuraciones entrenadas y no para reentrenar los algoritmos. Los experimentos reproducibles se ejecutan con múltiples semillas aleatorias por algoritmo, normalmente 20 repeticiones, para estimar la variabilidad estocástica de los heurísticos.

- 4.6. Evaluación fuera de muestra y robustez ante volatilidad: Una vez entrenados los modelos de optimización mediante sus respectivas heurísticas (ABC-FA, ABC-FA-EM y ABC-GSA), se procede a evaluar su desempeño fuera de muestra. Esta evaluación tiene como propósito determinar la capacidad de generalización de las soluciones encontradas, así como su robustez en contextos de alta incertidumbre, fluctuaciones abruptas y condiciones de estrés financiero, como las observadas en los mercados durante eventos exógenos o ciclos de alta volatilidad.

El enfoque seguido consiste en un backtesting estructurado con ventanas móviles, donde se simula un proceso de toma de decisiones realista. Para ello, se define un periodo de entrenamiento de 252 días (equivalente a un año bursátil) y una ventana de prueba de 21 días (aproximadamente un mes). Esta estructura se repite secuencialmente, moviendo ambas ventanas hacia adelante día a día, recalibrando el modelo únicamente con información del pasado para evitar cualquier tipo de sesgo retrospectivo. De esta forma, se garantiza que los pesos obtenidos reflejan decisiones basadas exclusivamente en información disponible hasta ese momento.

Durante cada iteración fuera de muestra, los portafolios optimizados se revalúan en función del retorno ex post, la varianza y métricas adicionales como el Ratio de Sharpe:

- Retorno observado fuera de muestra:

$$R_p = \sum(w_i * r_i) \quad (23)$$

Donde r_i representa el retorno observado del activo i en el periodo de prueba.

- Volatilidad ex post:

$$\sigma_p = \text{sqrt}(w^T * \Sigma * w) \quad (24)$$

Donde Σ es la matriz de varianzas y covarianzas calculada durante el entrenamiento.

- Ratio de Sharpe ajustado a una tasa libre de riesgo r_f :

$$S = \frac{(R_p - r_f)}{\sigma_p} \quad (25)$$

Además de estas métricas clásicas, se incorporan medidas de pérdida como el Valor en Riesgo (VaR) y el Expected Shortfall (ES) bajo supuestos no paramétricos:

- VaR al nivel de confianza α :

$$VaR_\alpha = -\text{quantile}(R_p, 1 - \alpha) \quad (26)$$

- Expected Shortfall:

$$ES_\alpha = -\text{mean}(R_p \leq VaR_\alpha) \quad (27)$$

Estas medidas permiten capturar de manera más realista la magnitud de posibles pérdidas extremas en eventos adversos.

4.6.1. Regímenes de volatilidad: La identificación y clasificación de los regímenes de volatilidad constituye una fase importante de esta tesis, ya que permite evaluar cómo los modelos de optimización de portafolio se comportan bajo distintos entornos de mercado. Este análisis es fundamental para analizar la robustez y adaptabilidad de los algoritmos. El siguiente cuadro muestra los distintos regímenes de volatilidad, explicando sus características y la información utilizada para clasificarlos, incluyendo indicadores de mercado y macroeconómicos relevantes:

Régimen de volatilidad	Características del mercado	Indicadores utilizados
Crisis	Periodos de fuerte tensión financiera global, alta incertidumbre, caídas significativas de precios de activos, aumento de correlaciones entre activos de riesgo y flight-to-quality pronunciado.	Percentil 75+ de volatilidad histórica (VIX y Nasdaq-100), caídas abruptas en índices bursátiles, shocks macroeconómicos.
Volatilidad elevada	Mercados con fluctuaciones elevadas, pero sin colapso sistémico; incertidumbre geopolítica o shocks	Percentil 50-75 de volatilidad histórica, aumento temporal de

	sectoriales que generan riesgo elevado.	correlaciones entre activos de riesgo.
Estabilidad	Mercados con variaciones moderadas, baja incertidumbre y correlaciones normales entre activos; crecimiento macroeconómico sostenido.	Percentil 0-50 de volatilidad histórica, VIX bajo, indicadores macroeconómicos estables (PIB, inflación y tasas de interés en rangos esperados).

La operacionalización de estos regímenes se apoya en umbrales específicos del índice VIX: crisis ($VIX \geq 35$), incertidumbre ($20 \leq VIX < 35$) y estabilidad ($VIX < 20$). Estos umbrales se sustentan en la literatura desde tres perspectivas complementarias. En primer lugar, Whaley (2000, 2009), creador del VIX como “investor fear gauge”, identifica un nivel de alerta de 30 como frontera entre periodos de alta y baja volatilidad en el mercado accionario estadounidense; el umbral de 35 adoptado en este estudio es deliberadamente más conservador, reservando la clasificación de crisis para episodios de estrés genuinamente extremo.

En segundo lugar, el promedio histórico de largo plazo del VIX (1990–2024) se sitúa entre 19 y 20, lo que implica que clasificar como “estabilidad” los periodos con VIX inferior a 20 equivale a identificar condiciones de volatilidad en o por debajo de la media histórica. En tercer lugar, el análisis de la distribución empírica del VIX muestra que el percentil 75 se ubica aproximadamente en 23–25, el percentil 90 en 30–33 y el percentil 95 en torno a 35–37 (CBOE, 2024; FRED, 2024), lo cual confirma que el umbral de 35 corresponde a condiciones de estrés extremo situadas en la cola superior de la distribución.

Adicionalmente, estudios recientes de optimización de portafolios condicionada por régimen, como RegimeFolio (Singh et al., 2025), emplean clasificaciones basadas en percentiles del VIX rolling de 252 días con terciles que producen umbrales promedio de 17,8 y 23,1, valores consistentes con el rango adoptado en esta investigación.

Para una evaluación profunda del comportamiento algorítmico, los periodos de prueba se han clasificado en regímenes de volatilidad específicos. Esta segmentación permite observar la adaptabilidad de los algoritmos en diversos escenarios de mercado:

- 4.6.1.1. Regímenes de crisis: Estos incluyen la crisis financiera global de 2008 y la pandemia de COVID-19 (2020). Se caracterizan por caídas bursátiles pronunciadas, incertidumbre sistémica y un aumento significativo en la aversión al riesgo.
- 4.6.1.2. Regímenes de volatilidad elevada: Abarcan episodios de alta fluctuación sin un colapso sistémico, como el período de la guerra en Ucrania (2022-2023). En estos momentos, se observan incrementos temporales en la volatilidad y el riesgo de mercado, aunque con una dinámica diferente a la de una crisis.
- 4.6.1.3. Regímenes de estabilidad: Corresponden a intervalos de baja volatilidad y condiciones macroeconómicas relativamente normales, con crecimiento sostenido y correlaciones moderadas entre activos (2015-2019 y 2024).

La capacidad de respuesta de los algoritmos metaheurísticos frente a la inestabilidad se manifiesta en su habilidad para adaptarse a cambios abruptos en la estructura de correlación entre activos. Este aspecto es especialmente crítico en episodios de flight-to-quality, donde la intensificación de las correlaciones entre activos de riesgo reduce drásticamente las oportunidades de diversificación efectiva. En estos contextos desafiantes, los modelos ABC-FA, ABC-FAEM y ABC-GSA han demostrado la capacidad de identificar soluciones menos concentradas. Esto se logra al privilegiar combinaciones que, gracias a sus mecanismos de exploración guiada (como la atracción por luciérnagas en ABC-FA o la atracción gravitacional en ABC-GSA), mantienen niveles estables de varianza controlada sin sacrificar de forma desproporcionada el retorno esperado.

Esta evidencia refuerza la tesis central de que el diseño adaptativo de los algoritmos presentados permite encontrar soluciones con un trade-off riesgo-retorno superior bajo condiciones de incertidumbre. La habilidad de estas variantes para generar portafolios más resilientes y menos concentrados, incluso cuando los mercados experimentan perturbaciones significativas, es un pilar fundamental de este estudio.

- 4.7. Métricas de comparación y análisis de desempeño: Con el fin de evaluar de manera rigurosa y multidimensional la calidad de las soluciones generadas por los modelos de optimización propuestos, se han definido un conjunto de métricas que permiten capturar distintos aspectos del desempeño de los portafolios. Estas métricas no solo consideran los criterios tradicionales de retorno y riesgo, sino que también incorporan elementos de

regularidad, eficiencia y robustez bajo escenarios de volatilidad, coherentes con los objetivos planteados en esta investigación. Las métricas utilizadas se agrupan en tres categorías principales:

4.7.1. Desempeño ajustado al riesgo:

- Ratio de Sortino para capturar la eficiencia frente a volatilidad negativa.
- Alfa de Jensen anual para medir capacidad de generar retornos diferenciales frente al benchmark Nasdaq-100.
- Ratio de Omega como medida complementaria de eficiencia en la distribución completa de retornos.
- Riesgo extremo y pérdidas
 - Máximo Drawdown para medir la peor pérdida acumulada entre pico y valle.
 - CVaR al 99% para cuantificar pérdida esperada en la cola.
 - Valor en Riesgo no paramétrico para niveles 95% y 99%.
- Estructura y diversificación
 - Herfindahl–Hirschman Index HHI para medir concentración.
 - Número efectivo de activos NEA para captar diversificación efectiva.
 - Análisis de composición sectorial y peso de activos seleccionados en cada periodo.

4.7.2. Pruebas estadísticas: Para comparar modelos se emplean pruebas no paramétricas sobre métricas como Sortino, por ejemplo la prueba de Wilcoxon entre pares de algoritmos para verificar si diferencias observadas son significativas al nivel deseado.

5. Resultados

La evaluación empírica de los algoritmos de optimización de portafolios ABC-Original, ABC-FAEM y ABC-GSA se presenta a continuación para cuatro períodos históricos diferenciados, cada uno asociado a un régimen de mercado específico. Los resultados se reportan considerando dos criterios alternativos de selección del universo de activos, el Z-score dinámico de mercado y el Z-score de fundamentales financieros, y se analizan en términos de métricas de desempeño ajustadas por riesgo, pérdida extrema y diversificación.

5.1. Z-score Dinámico: En esta subsección se presentan los resultados obtenidos bajo el criterio de selección del universo definido mediante el Z-score dinámico de mercado.

5.1.1. Régimen de Estabilidad (2023-01-01 a 2024-12-31)

Algoritmo	Sortino	Max Drawdown	Jensen Alpha	Omega Ratio
ABC_Original	4,00	-0,105	0,260	1,495
ABC_FA	2,31	-0,078	0,026	1,281
ABC_FAEM	4,14	-0,094	0,247	1,516
ABC_GSA	4,15	-0,102	0,298	1,515
PMVG_CVX	2,09	-0,069	0,056	1,257
Equally_Weighted	2,24	-0,070	0,021	1,272

En este régimen de mercado estable, se observa que los algoritmos que incorporan la lógica del ABC presentan un mejor desempeño en términos de retorno ajustado por riesgo. En particular, ABC_GSA y ABC_FAEM exhiben los Sortino Ratios más altos (4,15 y 4,14 respectivamente), superando al ABC_Original (4,00) y a los benchmarks PMVG_CVX (2,09) y Equally Weighted (2,24). Este patrón es consistente con la incorporación de mecanismos de búsqueda guiada, ya sea mediante atracción

gravitacional o adaptación del algoritmo de luciérnagas, lo que favorece una exploración más eficiente del espacio de soluciones en condiciones de mercado relativamente predecibles, permitiendo capturar oportunidades de retorno sin incurrir en una mayor exposición a pérdidas extremas.

El Max Drawdown es similar entre los algoritmos, con PMVG_CVX y Equally Weighted registrando las menores caídas (-0,069 y -0,070), aunque con un desempeño ajustado por riesgo considerablemente inferior. El Jensen Alpha de 0,298 para ABC_GSA es el más elevado del conjunto, lo que indica una mayor generación de exceso de retorno en relación con el riesgo sistemático.

5.1.2. Régimen de Crisis (COVID-2020: 2020-02-01 a 2020-07-30)

Algoritmo	Sortino	Max Drawdown	Jensen Alpha	Omega Ratio
ABC_Original	3,94	-0,357	1,163	1,558
ABC_FA	2,10	-0,333	0,474	1,302
ABC_FAEM	3,79	-0,334	1,099	1,526
ABC_GSA	3,82	-0,376	1,164	1,540
PMVG_CVX	2,67	-0,219	0,474	1,395
Equally_Weighted	1,93	-0,309	0,379	1,280

La crisis de COVID-2020, caracterizada por una caída abrupta y una recuperación relativamente rápida, constituye un escenario exigente para evaluar la resiliencia de los algoritmos de optimización. En este contexto, se observa que ABC_Original presenta el Sortino Ratio más alto (3,94), seguido de cerca por ABC_FAEM (3,79) y ABC_GSA (3,82),

lo que indica que estas estrategias logran mantener un desempeño ajustado por riesgo relativamente elevado aun en condiciones de estrés.

El Max Drawdown es significativo para todos los enfoques, aunque PMVG_CVX registra la menor caída (-0,219), en línea con su objetivo de minimización de varianza. No obstante, su Sortino Ratio (2,67) es inferior al de los algoritmos basados en ABC, reflejando una menor eficiencia en la relación entre retorno y riesgo a la baja. El Jensen Alpha de ABC_GSA (1,164) y ABC_Original (1,163) es el más elevado del conjunto, lo que sugiere una mayor capacidad para generar retornos por encima de lo esperado en un entorno de elevada incertidumbre.

5.1.3. Crisis Financiera Global (GFC-2008: 2007-10-01 a 2009-03-30)

Algoritmo	Sortino	Max Drawdown	Jensen Alpha	Omega Ratio
ABC_Original	-0,104	-0,486	0,359	0,988
ABC_FA	-0,551	-0,530	0,239	0,933
ABC_FAEM	-0,215	-0,501	0,330	0,974
ABC_GSA	-0,271	-0,493	0,314	0,967
PMVG_CVX	-0,957	-0,504	0,091	0,889
Equally_Weighted	-0,849	-0,569	0,166	0,898

La GFC-2008 representa un período de colapso sistémico prolongado, en el cual la diversificación tradicional se vio severamente comprometida. En este contexto, se observa que todos los algoritmos presentan Sortino Ratios negativos y Max Drawdowns elevados, lo que resulta esperable en un mercado bajista severo. No obstante, ABC_Original (-0,104) y ABC_FAEM (-0,215) registran los Sortino Ratios menos negativos, lo que indica una mejor gestión del riesgo a la baja en comparación con ABC_FA (-0,551), PMVG_CVX (-0,957) y Equally Weighted (-0,849).

El Max Drawdown es similar entre los algoritmos ABC y PMVG_CVX, con valores en torno a -0,48 y -0,50, mientras que Equally Weighted experimenta la mayor caída (-0,569). El Jensen Alpha de ABC_Original (0,359) es el más elevado del conjunto, lo que sugiere que, aun en un entorno de mercado altamente adverso, este enfoque logra un desempeño relativo superior frente al riesgo sistemático, consistente con una mayor capacidad de adaptación de su mecanismo de exploración en escenarios donde la estructura del espacio de soluciones se degrada.

5.1.4. Régimen de Volatilidad (2022-02-01 a 2022-08-01)

Algoritmo	Sortino	Max Drawdown	Jensen Alpha	Omega Ratio
ABC_Original	0,758	-0,232	0,432	1,086
ABC_FA	-0,076	-0,280	0,266	0,992
ABC_FAEM	0,544	-0,256	0,429	1,061
ABC_GSA	0,978	-0,191	0,518	1,110
PMVG_CVX	0,265	-0,242	0,201	1,032
Equally_Weighted	-0,361	-0,314	0,210	0,961

En este régimen, caracterizado por fluctuaciones significativas sin constituir una crisis sistémica completa, se observa que los algoritmos presentan diferencias relevantes en su desempeño bajo condiciones de elevada incertidumbre. En particular, ABC_GSA se destaca con el Sortino Ratio más alto (0,978) y el Max Drawdown más bajo (-0,191), superando al resto de los algoritmos y a los benchmarks. Este comportamiento es consistente con la incorporación de un mecanismo de búsqueda guiada de tipo gravitacional, que favorece una exploración más efectiva del espacio de soluciones en entornos volátiles, permitiendo contener las caídas y mantener una mejor relación entre retorno y riesgo.

ABC_Original también presenta un desempeño relativamente sólido (Sortino de 0,758 y Max Drawdown de -0,232). El Jensen Alpha de ABC_GSA (0,518) es el más elevado del conjunto, lo que indica una mayor capacidad para generar exceso de retorno en condiciones de mercado desafiantes. En contraste, ABC_FA y Equally Weighted registran Sortino Ratios negativos, lo que refleja una menor efectividad para gestionar el riesgo a la baja en este tipo de entorno.

En conjunto, los resultados obtenidos bajo el criterio de selección definido por el Z-score dinámico muestran diferencias relevantes en el desempeño de los algoritmos evaluados a través de los distintos regímenes de mercado. Mientras que el ABC_Original presenta una mayor resiliencia relativa en episodios de crisis como COVID-2020, las variantes ABC_FAEM y, especialmente, ABC_GSA exhiben un mejor desempeño en términos de retorno ajustado por riesgo y control del Max Drawdown en contextos de estabilidad y volatilidad elevada. Esta evidencia empírica permite caracterizar patrones diferenciados de comportamiento entre los algoritmos bajo distintos entornos de mercado, los cuales se describen a partir de las métricas observadas, sin atribuir mecanismos causales directos más allá de los resultados reportados.

5.2. Z-score Fundamentales Financieros:

En esta subsección se presentan los resultados obtenidos bajo el criterio de selección del universo definido mediante el Z-score de fundamentales financieros.

5.2.1. Régimen de Estabilidad (2023-01-01 a 2024-12-31)

Algoritmo	Sortino	Max Drawdown	Jensen Alpha	Omega Ratio
ABC_Original	4,896	-0,149	0,351	1,616
ABC_FA	3,727	-0,083	0,119	1,481
ABC_FAEM	4,888	-0,148	0,331	1,616

ABC_GSA	5,011	-0,135	0,329	1,637
PMVG_CVX	1,941	-0,061	0,029	1,243
Equally_Weighted	3,305	-0,079	0,075	1,414

En el régimen de estabilidad, los algoritmos híbridos muestran una ventaja significativa frente a los enfoques tradicionales, aunque con diferencias en sus fortalezas. El ABC_GSA lidera con el Sortino Ratio más alto (5,01) y un Omega Ratio de 1,64, lo que indica una mayor eficiencia en la generación de retornos positivos por unidad de riesgo negativo y una probabilidad más alta de escenarios de ganancia frente a pérdida. Este comportamiento se asocia con una mejor relación entre retorno y riesgo, manteniendo estabilidad en la asignación del portafolio.

Por su parte, el ABC_FAEM alcanza un Sortino Ratio muy cercano (4,89) y un Omega Ratio de 1,61, confirmando que la lógica de atracción por luciérnagas mejora la explotación local sin perder diversidad, lo que se traduce en portafolios con alta consistencia y control de riesgo. Aunque su Jensen Alpha (0,331) es ligeramente inferior al del modelo gravitacional, sigue siendo positivo y relevante, lo que indica capacidad para generar alfa frente al Nasdaq-100.

El ABC_FA, si bien presenta métricas más moderadas (Sortino Ratio de 3,72 y Omega Ratio de 1,48), destaca por su menor drawdown (-0,083), lo que refleja una estrategia más defensiva en términos de pérdidas extremas. Este comportamiento es consistente con una priorización de la reducción de caídas frente a la maximización del retorno ajustado por riesgo.

En contraste, el modelo Media-Varianza (PMVG_CVX) muestra un Sortino Ratio considerablemente menor (1,94) y un Omega Ratio apenas superior a 1, lo que evidencia que, aunque logra reducir el drawdown, sacrifica eficiencia en la relación riesgo-retorno. El enfoque equiponderado (1/N), si bien ofrece diversificación máxima, carece de optimización, quedando por debajo de los algoritmos híbridos en todas las métricas, lo que confirma que la simplicidad no compensa la falta de adaptabilidad en la construcción del portafolio.

5.2.2. Régimen de Crisis (COVID-2020)

Algoritmo	Sortino	Max Drawdown	Jensen Alpha	Omega Ratio
ABC_Original	4,648	-0,188	1,065	1,630
ABC_FA	2,410	-0,268	0,473	1,341
ABC_FAEM	4,290	-0,195	0,980	1,576
ABC_GSA	4,484	-0,188	1,055	1,591
PMVG_CVX	3,808	-0,126	0,676	1,518
Equally_Weighted	2,079	-0,254	0,367	1,303

En el régimen de crisis asociado a la pandemia de COVID-19, caracterizado por caídas abruptas, alta correlación entre activos y un incremento significativo en la aversión al riesgo, se observa que los algoritmos híbridos presentan un mejor desempeño relativo en la gestión del riesgo a la baja y en la preservación de la eficiencia ajustada por riesgo. El ABC_GSA alcanza un Sortino Ratio de 4,48, apenas por debajo del ABC_Original (4,65), lo que indica que ambos modelos logran generar retornos positivos por unidad de riesgo negativo en un entorno altamente adverso, donde la mayoría de las estrategias tradicionales tienden a deteriorarse. Este resultado es particularmente relevante dado que el Sortino Ratio, al penalizar únicamente la volatilidad negativa, refleja la capacidad de los algoritmos para contener pérdidas extremas sin eliminar completamente las oportunidades de recuperación.

El Omega Ratio superior a 1,59 indica que la probabilidad de escenarios de ganancia frente a pérdida se mantiene favorable incluso bajo un umbral mínimo exigente, lo que da cuenta de una mayor resiliencia del modelo en condiciones de estrés. Asimismo, el Jensen Alpha positivo de ABC_GSA (1,055) evidencia una generación de exceso de retorno frente al Nasdaq-100 durante este período. En comparación, el modelo Media-Varianza (PMVG_CVX) registra un drawdown menor (-0,126), coherente con su objetivo de

minimización de varianza, aunque presenta valores inferiores de Sortino Ratio (3,80) y Omega Ratio (1,51), lo que refleja una menor eficiencia en la relación entre retorno y riesgo a la baja. El enfoque equiponderado (1/N), aunque simple, muestra una mayor vulnerabilidad, con un Sortino Ratio reducido (2,07) y un drawdown más elevado (-0,254), confirmando que la diversificación uniforme no compensa la ausencia de optimización en escenarios de crisis.

5.2.3. Crisis Financiera Global (GFC-2008)

Algoritmo	Sortino	Max Drawdown	Jensen Alpha	Omega Ratio
ABC_Original	0,361	-0,364	0,403	1,045
ABC_FA	-0,161	-0,425	0,341	0,981
ABC_FAEM	0,342	-0,359	0,405	1,042
ABC_GSA	0,324	-0,358	0,380	1,040
PMVG_CVX	-0,135	-0,399	0,252	0,983
Equally_Weighted	-0,513	-0,519	0,259	0,940

En el régimen correspondiente a la crisis financiera global, caracterizado por un colapso sistémico prolongado, correlaciones extremas entre activos y una pérdida generalizada de liquidez, se observa que todos los modelos experimentan un deterioro significativo en sus métricas, lo que refleja la dificultad de mantener eficiencia en entornos donde la diversificación tradicional se ve prácticamente anulada. Aun así, los algoritmos híbridos muestran señales de resiliencia relativa: el ABC_Original y el ABC_FAEM registran Sortino Ratios positivos (0,361 y 0,342 respectivamente), mientras que el ABC_GSA mantiene un desempeño estable con un Sortino Ratio de 0,324, frente a los benchmarks que presentan valores negativos (PMVG_CVX: -0,135; 1/N: -0,513).

Este patrón indica que, incluso bajo condiciones extremas, los mecanismos de búsqueda guiada incorporados en los algoritmos bioinspirados contribuyen a evitar asignaciones excesivamente concentradas, reduciendo la exposición a pérdidas desproporcionadas. El Omega Ratio cercano a 1,04 en los modelos híbridos sugiere que la probabilidad de escenarios de ganancia frente a pérdida se mantiene relativamente equilibrada, mientras que los benchmarks se sitúan por debajo de 0,98, evidenciando una mayor vulnerabilidad estructural.

El Jensen Alpha positivo, con valores comprendidos entre 0,380 y 0,405 en los algoritmos híbridos, resulta particularmente relevante, ya que indica la capacidad de estos enfoques para generar exceso de retorno ajustado por riesgo sistemático aun en un contexto adverso. En conjunto, estos resultados muestran que, si bien ningún modelo logra eliminar el impacto de crisis sistémicas, los enfoques bioinspirados presentan una gestión más eficiente del riesgo extremo y una estructura de portafolio menos frágil frente a choques prolongados.

5.2.4. Régimen de Volatilidad Elevada (2022)

Algoritmo	Sortino	Max Drawdown	Jensen Alpha	Omega Ratio
ABC_Original	0,744	-0,153	0,291	1,095
ABC_FA	0,127	-0,180	0,236	1,015
ABC_FAEM	0,811	-0,136	0,337	1,100
ABC_GSA	0,669	-0,132	0,252	1,083
PMVG_CVX	-0,333	-0,128	0,035	0,961
Equally_Weighted	-0,466	-0,196	0,129	0,949

En el régimen de volatilidad elevada correspondiente al año 2022, caracterizado por fluctuaciones significativas en los precios, incremento temporal en las correlaciones entre activos y episodios de incertidumbre geopolítica, los algoritmos híbridos demuestran una capacidad superior para mantener eficiencia ajustada al riesgo frente a los benchmarks tradicionales. El ABC_FAEM destaca con el Sortino más alto (0,811) y un Omega Ratio de 1,100, lo que indica que, aun en un entorno incierto, el portafolio optimizado mantiene una probabilidad favorable de escenarios de ganancia frente a pérdida, superando el umbral mínimo aceptable. Este comportamiento se complementa con un Jensen Alpha de 0,337, que confirma la generación de exceso de retorno frente al Nasdaq-100 ajustado por riesgo sistemático, validando la capacidad del modelo para capturar oportunidades en mercados volátiles sin sacrificar estabilidad.

El ABC_GSA, aunque con un Sortino ligeramente inferior (0,669), logra el menor drawdown (-0,132), lo que evidencia su fortaleza en la contención de pérdidas extremas, atributo crítico en entornos donde la dispersión de retornos se amplifica. En contraste, el modelo Media-Varianza (PMVG_CVX) presenta Sortino negativo (-0,333) y Omega inferior a 1 (0,961), lo que refleja vulnerabilidad estructural ante cambios abruptos en la matriz de correlaciones. El enfoque equiponderado (1/N) muestra un desempeño aún más débil, con Sortino negativo (-0,466) y drawdown elevado (-0,196), confirmando que la simplicidad no compensa la falta de adaptabilidad en escenarios de alta volatilidad. En conjunto, estos resultados refuerzan la hipótesis central: los mecanismos de búsqueda guiada y atracción gravitacional permiten construir portafolios más resilientes y eficientes en entornos caracterizados por incertidumbre y riesgo elevado.

Al comparar los resultados obtenidos bajo el Z-score dinámico y el Z-score de fundamentales financieros, se observan tanto similitudes como diferencias relevantes en el desempeño de los algoritmos evaluados. En ambos casos, las variantes híbridas ABC_FAEM y ABC_GSA mantienen una ventaja consistente frente a ABC_Original y ABC_FA, registrando Sortino Ratios superiores y niveles de drawdown más contenidos, lo que refleja un desempeño relativamente más robusto bajo distintos regímenes de volatilidad. Por su parte, los benchmarks tradicionales, Media-Varianza y 1/N, muestran de manera sistemática un menor desempeño ajustado por riesgo, especialmente en escenarios de crisis y volatilidad elevada, donde su menor capacidad de adaptación se traduce en pérdidas más pronunciadas y ratios de eficiencia reducidos.

Las diferencias más marcadas entre ambos criterios de selección se manifiestan en la composición y diversificación de los portafolios resultantes. Bajo el Z-score de fundamentos financieros, los algoritmos híbridos tienden a generar una cardinalidad ligeramente mayor, lo que permite capturar un conjunto más amplio de oportunidades dentro del universo

considerado y contribuye a una reducción marginal del riesgo idiosincrático. Este patrón se asocia con mejoras adicionales en los Sortino Ratios y un mayor control de los drawdowns, particularmente en regímenes adversos como la crisis de COVID-2020 y el período de elevada volatilidad de 2022. En entornos de estabilidad, la ventaja relativa de los algoritmos híbridos se mantiene, aunque el modelo Media-Varianza reduce parcialmente la brecha debido a su menor sensibilidad a episodios de estrés extremo.

En conjunto, estos resultados permiten caracterizar diferencias sistemáticas en el comportamiento de los modelos bajo distintos criterios de selección del universo, reflejando ajustes en la relación entre riesgo y retorno asociados al tipo de información utilizada en la construcción de los portafolios.

6. Conclusiones

Sobre el diseño, implementación y calibración de las variantes ABC-FAEM y ABC-GSA

La incorporación de mecanismos de exploración guiada en la fase de scout del algoritmo ABC demostró ser viable y efectiva. El ABC-FAEM, al reemplazar el reinicio aleatorio del scout por una atracción dirigida hacia las mejores soluciones mediante lógica de luciérnagas con selección softmax, logró una convergencia más controlada sin sacrificar la diversidad del enjambre. El ABC-GSA, al incorporar un mecanismo de fuerza gravitacional proporcional a la aptitud relativa de las soluciones, generó una dinámica cooperativa que favorece la intensificación hacia regiones de alto desempeño.

Desde la perspectiva metodológica, la calibración de hiperparámetros basada en regímenes sintéticos constituye uno de los aportes más relevantes de esta tesis. En lugar de optimizar sobre un historial específico (lo cual suele derivar en sobreajuste), se sometió a los algoritmos a escenarios de estrés fabricados que simulan expansiones de volatilidad, incrementos de correlaciones y eventos de cisne negro. La estabilidad de las ejecuciones fuera de muestra demuestra que el desempeño superior de los modelos híbridos no proviene de un ajuste oportunista a datos pasados, sino de una estructura de búsqueda que desarrolló verdadera adaptabilidad ante entornos financieros volátiles.

Sobre la evaluación comparativa bajo distintos regímenes de volatilidad

El análisis segmentado por regímenes valida la hipótesis central de esta investigación, pero revela un hallazgo crítico: la dominancia algorítmica depende del tipo de régimen. En fases

de volatilidad elevada sin colapso sistémico (guerra 2022) y en regímenes de estabilidad (2023–2024), las variantes propuestas superaron consistentemente al ABC original y a los benchmarks tradicionales. El ABC-GSA alcanzó los Sortino Ratios más altos (hasta 5,01 en estabilidad) y los menores Maximum Drawdowns, mientras que el ABC-FAEM mostró la mejor eficiencia en la relación riesgo-retorno durante episodios de volatilidad elevada (Sortino de 0,81 vs. -0,33 del modelo Media-Varianza). En ambos escenarios, los benchmarks tradicionales (PMVG_CVX y 1/N) registraron Sortino negativos o significativamente inferiores, confirmando su vulnerabilidad estructural ante cambios en la matriz de correlaciones.

Sin embargo, en colapsos sistémicos prolongados (GFC 2008, COVID-19), el ABC original demostró una resiliencia inesperada, registrando Sortinos competitivos o superiores a las variantes híbridas. Este comportamiento indica que, frente a escenarios donde las correlaciones se elevan y las zonas prometedoras del espacio de soluciones desaparecen, los saltos estocásticos completamente aleatorios de la abeja exploradora actúan como un mecanismo de diversificación extrema, superando a las estrategias de atracción que intentan buscar refugios donde simplemente no los hay. En términos prácticos, los resultados indican que los algoritmos bioinspirados híbridos representan una alternativa viable para la gestión institucional de portafolios en contextos de alta incertidumbre, particularmente frente a restricciones no convexas y alta dimensionalidad. Si bien implican mayores costos computacionales y una calibración inicial más fina, los beneficios en preservación de capital y eficiencia ajustada al riesgo justifican plenamente su adopción.

Sobre el efecto de la selección de universo mediante Z-score

El filtro previo de activos mediante Z-score no es un paso accesorio, sino una capa de defensa primaria dentro de la arquitectura de optimización. Al reevaluar dinámicamente el universo elegible y excluir información futura (eliminando el look-ahead bias), el Z-score actúa como escudo antes de la fase de optimización. La comparación entre ambos enfoques de selección reveló que el Z-score de fundamentales financieros potencia el desempeño de los algoritmos híbridos: el ABC-GSA alcanzó un Sortino de 5,01 con fundamentales frente a 4,15 con Z-score dinámico en estabilidad; durante la GFC 2008, el ABC-Original pasó de un Sortino negativo (-0,10) con Z-score dinámico a positivo (0,36) con fundamentales. Además, el Z-score de fundamentales tendió a generar mayor cardinalidad en los portafolios, capturando más oportunidades y reduciendo el riesgo idiosincrático.

Limitaciones y líneas de investigación futura

Este trabajo reconoce ciertas limitaciones. La dependencia de datos históricos para la parametrización base de los regímenes sintéticos requiere validaciones continuas antes de su paso a producción operativa. No obstante, estas limitaciones abren líneas claras de investigación futura, entre ellas la integración de modelos de *Machine Learning* para la predicción anticipada de cambios de régimen, la incorporación explícita de costos de transacción, y la extensión de este marco algorítmico a otras clases de activos alternativos y mercados emergentes.

7. Referencias

1. Bengio, Y. (2009). Learning deep architectures for AI. *Foundations and Trends in Machine Learning*, 2(1). <https://doi.org/10.1561/22000000006>
2. Best, M. J., & Grauer, R. R. (1991). On the sensitivity of mean–variance-efficient portfolios to changes in asset means: Some analytical and computational results. *The Review of Financial Studies*, 4(2), 315–342.
3. Black, F., & Litterman, R. (1992). Global portfolio optimization. *Financial Analysts Journal*, 48(5), 28–43.
4. Blum, C., & Roli, A. (2003). Metaheuristics in combinatorial optimization: Overview and conceptual comparison. *ACM Computing Surveys*, 35(3), 268–308.
5. Campbell, J. Y., & Viceira, L. M. (2002). *Strategic asset allocation: Portfolio choice for long-term investors*. Oxford University Press.
6. Chakraborty, A., & Kar, A. (2017). Swarm intelligence: A review of algorithms. In *Nature-inspired computing and optimization: Theory and applications*. Springer.
7. Chen, A., Liang, Y., & Liu, C. (2012). An artificial bee colony algorithm for the cardinality-constrained portfolio optimization problem. In *Proceedings of the IEEE Congress on Evolutionary Computation*.
8. Chen, A., Liang, Y., & Liu, C. (2013). Portfolio optimization using an improved artificial bee colony approach. In *Proceedings of the IEEE Conference on Computational Intelligence for Financial Engineering and Economics*.
9. Chicago Board Options Exchange (CBOE). (2024). Cboe Volatility Index (VIX) methodology. https://www.cboe.com/tradable_products/vix/
10. Deb, K. (2001). *Multi-objective optimization using evolutionary algorithms*. Wiley-Interscience.
11. De Jong, K. A. (2008). *Evolutionary computation: A unified approach*. MIT Press.

12. DeMiguel, V., Garlappi, L., & Uppal, R. (2009). Optimal versus naïve diversification: How inefficient is the 1/N portfolio strategy? *The Review of Financial Studies*, 22(5), 1915–1953.
13. Ertenlice, O., & Kalayci, C. B. (2018). A survey of swarm intelligence for portfolio optimization: Algorithms and applications. *Swarm and Evolutionary Computation*, 39, 36–52. <https://doi.org/10.1016/j.swevo.2018.01.009>
14. Erwin, K., & Engelbrecht, A. (2023). Meta-heuristics for portfolio optimization. *Applied Soft Computing*, 134.
15. Fama, E. F., & French, K. R. (1992). The cross-section of expected stock returns. *The Journal of Finance*, 47(2), 427–465.
16. Genetic algorithms in search, optimization, and machine learning. (1989). *Choice Reviews Online*, 27(2). <https://doi.org/10.5860/choice.27-0936>
17. Gunjan, A., & Bhattacharyya, S. (2023). A brief review of portfolio optimization techniques. *Artificial Intelligence Review*, 56(5). <https://doi.org/10.1007/s10462-022-10273-7>
18. Hinton, G. E. (1986). Learning distributed representations of concepts. In *Proceedings of the Eighth Annual Conference of the Cognitive Science Society*.
19. Holland, J. H. (1975). *Adaptation in natural and artificial systems*. University of Michigan Press.
20. Houssein, E. H., Gad, A. G., Hussain, K., & Suganthan, P. N. (2021). Major advances in particle swarm optimization: Theory, analysis, and application. *Swarm and Evolutionary Computation*, 63. <https://doi.org/10.1016/j.swevo.2021.100868>
21. Jagannathan, R., & Ma, T. (2003). Risk reduction in large portfolios: Why imposing the wrong constraints helps. *The Journal of Finance*, 58(4), 1651–1684.
22. Jiang, X., & Li, S. (2017). Beetle antennae search algorithm for optimization problems. *Applied Soft Computing*, 62, 15–26.
23. Karaboga, D. (2005). An idea based on honey bee swarm for numerical optimization (Technical Report TR-06). Erciyes University.
24. Karaboga, D., & Akay, B. (2009). A comparative study of the artificial bee colony algorithm. *Applied Mathematics and Computation*, 214(1), 108–132.
25. Kennedy, J., & Eberhart, R. (1995). Particle swarm optimization. In *Proceedings of the IEEE International Conference on Neural Networks*.
26. Kolm, P. N., Tütüncü, R., & Fabozzi, F. J. (2014). Sixty years of portfolio optimization: Practical challenges and current trends. *European Journal of Operational Research*, 234(2), 356–371. <https://doi.org/10.1016/j.ejor.2013.10.060>
27. Kumar, D., & Mishra, K. (2017). Portfolio optimization using novel covariance-guided artificial bee colony algorithm. *Swarm and Evolutionary Computation*, 33, 119–130.

28. LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278–2324. <https://doi.org/10.1109/5.726791>
29. Mandal, P. K. (2023). A review of classical methods and nature-inspired algorithms for optimization problems. *Results in Control and Optimization*, 13. <https://doi.org/10.1016/j.rico.2023.100315>
30. Merton, R. C. (1969). Lifetime portfolio selection under uncertainty: The continuous-time case. *The Review of Economics and Statistics*, 51(3), 247–257.
31. Merton, R. C. (1971). Optimum consumption and portfolio rules in a continuous-time model. *Journal of Economic Theory*, 3(4), 373–413.
32. Rahmani, M., Eraqi, M., & Nikoomaram, M. (2019). Portfolio optimization by means of meta-heuristic algorithms. *Advances in Mathematical Finance and Applications*, 4(2).
33. Rashedi, E., Nezamabadi-Pour, H., & Saryazdi, S. (2009). GSA: A gravitational search algorithm. *Information Sciences*, 179(13), 2232–2248.
34. Ross, S. A. (1976). The arbitrage theory of capital asset pricing. *Journal of Economic Theory*, 13(3), 341–360.
35. Sharpe, W. F. (1964). Capital asset prices: A theory of market equilibrium under conditions of risk. *The Journal of Finance*, 19(3), 425–442.
36. Singh, A., et al. (2025). RegimeFolio: A regime-aware machine learning system for sectoral portfolio optimization in dynamic markets. *arXiv preprint*, arXiv:2510.14986. <https://arxiv.org/abs/2510.14986>
37. Talbi, E.-G. (2009). *Metaheuristics: From design to implementation*. Wiley.
38. Tobin, J. (1958). Liquidity preference as behavior toward risk. *The Review of Economic Studies*, 25(2), 65–86.
39. Tuba, M., & Bacanin, N. (2014). Artificial bee colony algorithm hybridized with firefly algorithm for cardinality-constrained mean-variance portfolio selection. *Applied Mathematics and Information Sciences*, 8(6), 2791–2801. <https://doi.org/10.12785/amis/080619>
40. Wang, Z., Liu, S., & Kong, X. (2012). Artificial bee colony algorithm for portfolio optimization problems. *International Journal of Advanced Computer Technology*, 4(6).
41. Whaley, R. E. (2000). The investor fear gauge. *The Journal of Portfolio Management*, 26(3), 12–17.
42. Whaley, R. E. (2009). Understanding the VIX. *The Journal of Portfolio Management*, 35(3), 98–105. <https://doi.org/10.3905/JPM.2009.35.3.098>
43. Yang, X.-S. (2009). Firefly algorithms for multimodal optimization. In *Stochastic algorithms: Foundations and applications*.